

2026 년 제 8 회 K-디지털 트레이닝 해커톤 아이디어 개발 기획서

참가팀명	준배	
참가과제 (택 1)	○ 지정과제	AI 전환 시대, 인간의 역량을 확장하는 디지털 서비스 개발
	● 자유과제	첨단·디지털 기술을 활용한 창의적 서비스 개발
아이디어 명칭	AI 얼굴인식·인공지능 합성 미디어 탐지 기술을 활용한 디지털 합성 미디어 피해 전주기(예방·탐지·대응·회복) 지원 서비스	
관련분야	인공지능, 사이버보안, 빅데이터	
1. 추진 배경	딥페이크 범죄 현장 실증	

1.1 딥페이크 범죄의 심각성

뉴스 · 2025.04.10. · 네이버뉴스


'딥페이크' 성범죄 피해, 1년간 227% 늘었다... 10·20대 92%

지난해 중앙디지털성범죄피해자지원센터(다성센터)가 지원한 딥페이크 성범죄 피해 규모가 전년 대비 3배 이상 늘어난 것으로 나타났다. 그 중 10대 및 20대가 차지하는 비율이 92%에 달했다. 10일 여성가족부와 한국...



'딥페이크' 성범죄 피해, 1년새 3배... 피해자 10명... 동행미디어 시대 · 2025.04.10. · 네이버뉴스

'딥페이크' 성범죄 피해, 1년간 227% 늘었다...10·20대 92% TV조선 · 2025.04.10. · 네이버뉴스




출처: 성평등가족부·한국여성인권진흥원, 「2025 디지털성범죄 피해자 지원보고서」

- 2025 년 기준 딥페이크 합성물로 인한 피해가 전년도에 비해 **227% 증가**함.
- 피해자 **10 명** 중 **9 명이 10·20 대**, 여성 피해자가 **75.4%** 차지.
- **유포 불안**은 **4884 건**으로 가장 높은 디지털성범죄 피해 유형.
→ **딥페이크 합성물에 의한 유포 문제**도 이에 해당.

2025년 디지털성범죄 피해 유형별 현황


※ ()안은 전년 대비 증감률, %

자료 : 성평등가족부 · 중앙디지털성범죄피해자지원센터



급증하는 디지털 성범죄 '10대 피해자'

자료=중앙디지털성범죄피해자지원센터



1.2 핵심 문제 정의

- 인지 어려움: 본인 얼굴이 실제 악용됐는지, 어디까지 유포됐는지 스스로 알기 어려움
- 사전 예방 부재: 합성을 막을 수단이 없어, 이미 유포된 뒤에 대응이 시작됨.
- 증거화·신고 관리: 증거물을 법적 효력이 있는 형태(URL·계정·시각)로 정리하기 어렵고, 각 플랫폼 별 신고 절차가 복잡함.

1.3 딥페이크 피해 지원 현황

- 공공 지원: 정부에서 제공하는 지원의 대부분이 피해영상을 삭제지원

→ 피해자 대비 지원 인력 부족, 탐지 시스템은 개인 접근 불가. 피해자 부담 ①

주요 지원 항목	실적(2025)	구조적 공백
삭제 지원	31.8 만 건(90.3%)	예방·탐지 기능 없음, 피해자가 직접 발견
AI 탐지 시스템	디성센터 내부 도입	개인 접근 불가
디성센터 지원 인력	중앙 37 명, 지역 15 개소×2 명(총 30 명)	연 1 만+ 피해자 대비 절대 부족

출처: 성평등가족부·한국여성인권진흥원, 「2025 디지털성범죄 피해자 지원보고서」(2026.4.16 보도자료),
성평등가족부 「2025 년 자체평가 결과보고서(주요정책 부문)」(2026.1)

- 기존 상용 서비스: 예방·탐지 중 하나만 제공 → 신고까지 피해 대응 전 주기 지원하는 서비스는 없음

서비스	예방	탐지	자동신고	접근성
Reality Defender / Intel FakeCatcher	×	O	×	B2B 전용
DeepShield	O	×	×	B2C, 무료
AI Guard (헥토이노베이션)	×	O	×	B2C, 월 4,400 원
카이캐치 / 라온 모바일 시큐리티	×	O	×	B2C, 무료·부가기능

- 법적 규제: 의무 조항은 갖춰졌지만, 개인이 직접 쓸 수 있는 실행 도구로는 연결되지 않음


구분	성폭력처벌법 14 조	AI 기본법 31 조	AI 선제적 대응 시스템
핵심 내용	반포 목적이 없어도, 제작·소지·시청한 경우 처벌대상	AI 서비스 사업자는 AI 합성 결과물임을 알 수 있게 표시해야 한다	딥페이크물 탐지·추적 및 삭제요청 자동화 시스템 고도화 추진

⇒ 피해자의 부담을 줄이고, 개인이 선제적 대응을 할 수 있는 도구의 필요성 확인됨.

1.4 비즈니스 모델


- 타겟: 만 19~24 세 여성 대학생(딥페이크 합성·편집 피해 집중군)을 초기 실증 대상으로 지정.
- 구조: 대학은 「고등교육법」상 학생 보호 의무를 이행할 실행 도구로 딥소각을 도입하고, 학생은 무료로 보호받는 B2B2C

고객	상품	과금 기준
개인 B2C	무료 1 회 노출 진단 + 선택형 예방·재검색	월 구독 또는 사용량 (피해건수 과금 금지)
대학·교육기관	12~16 주 실증 → 연간 디지털 안전 패키지	기관 기본료 + 포함 인원·API 구간
통신·보험 플랫폼	검색·증거화·동의 모듈 SDK/API	도입비 + 활성사용자·API 사용량

2. 개발 내용	해커톤 본선까지의 개발 파이프라인
2.1 구현 목표 - 검증 목표: ① 얼굴 등록부터 탐지 경보까지 자동 파이프라인 완주 ② 탐지 경보에서 신고서 생성·발송까지 10 분 이내 ③ 딥백신 적용 전후 딥페이크 합성 왜곡 육안 비교 시연 - 탐지 범위: 검색엔진 공개 웹 + 이용약관상 허용된 공개 SNS 영역으로 한정, 비공개 채널은 사용자·지인 제보로 보완 2.2 구현 기능 - 딥백신(사전 예방): SNS 에 사진 업로드 전, 사진에 적대적 노이즈 필터를 씌워 딥페이크 합성 결과를 왜곡하여 피해 예방 - 얼굴 가드(피해 자동탐지): 피해자가 직접 찾지 않아도 등록된 얼굴(외부 유출 방지)을 기준으로 공개 웹을 역이미지 검색으로 자동 순찰해 피해 후보 이미지 수집 - 증거 금고+즉각 소각(사후 대응): 피해 사실 인지 즉시 법적 증거 보존 처리, 각 플랫폼 별 신고서 초안 작성 및 전송 안내 2.3 사용자 시나리오	
	 <pre> graph TD User[사용자(본인) 셀카 3~5장 등록] --> Trash[원본 사진은 즉시 파기] User --> WebSearch((웹상 탐색 (후보 이미지 수집))) WebSearch --> DB[딥백신 기능 적대적 노이즈 삽입으로 딥페이크 합성 악용 방지 보호사진이 준비됐어요 원본은 그대로, 가시성 보강한 안전버전만 업로드해요. 보통 영상 공유 원본 사진 보호본] WebSearch --> IG[얼굴 가드 기능 업로드한 이미지로 탐지하여 딥페이크 합성을 발견 찾은 후보를 직접 확인해 주세요 얼굴 유사도와 합성 위험 수준을 따로 확인할 수 있어요. 후보 1 Bing ImageSearch 엔진 얼굴 유사도: 0.806 의사 지능 판정: 0.999 후보 2 Google ImageSearch 엔진 얼굴 유사도: 0.574 의사 지능 판정: 0.999 선택 후보 상세 보기] WebSearch --> ID[즉각 소각 기능 신고 절차 안내 및 사이트별 신고서 초안 작성 신고 절차 안내 사이트별 신고서 초안 작성 신고서 전송] WebSearch --> EV[증거 금고 기능 증거화면 캡처 및 원본 저장, 해시+TSA로 법적 증거 확보 증거화면 캡처 암호화 파일 저장 (본인 폰)] DB --> CUB[코사인 유사도 비교] CUB --> IG EV --> EC[증거화면 캡처] EC --> EF[암호화 파일 저장 (본인 폰)] </pre>

2.4 시스템 아키텍처

- React Native 앱 내에서 **얼굴 원본을 기기 밖으로 보내지 않고(보안 유지)** 임베딩만 생성하여 전달
- FastAPI 백엔드(AWS EC2·Docker)가 딥백신·판별·신고서 생성(RAG)·증거 해시 발급·외부 신고 연동을 처리하며, 데이터는 MySQL, 증거 원본은 S3에 암호화 저장
- **처리 흐름:** 자동탐지 → 판별 → 증거 보존 → 신고서 생성 → 신고기관 발송 순이며,
배포는 Git → GitHub Actions → AWS 무중단 배포로 자동화



3. 주요 특징 및 핵심 기술

딥소각 주요 기능 및 실험


3.1 데이터셋

딥소각의 핵심 기능인 얼굴가드는 사용자가 등록한 얼굴을 기준으로 공개 웹을 자동으로 순찰하여 무단으로 유포된 이미지를 탐지하고, 딥러닝 기반 얼굴 임베딩으로 동일 인물 여부를 정밀하게 판별하는 시스템이다. 이 절에서는 실험에 사용한 데이터셋을 먼저 소개한 뒤, 얼굴가드 탐지 파이프라인의 핵심 알고리즘인 ArcFace의 이론적 배경과 실제 서비스 적용 결과, 향후 고도화 방향을 실험을 통해 검증한다.

데이터	출처	활용 방안
FaceForensics++	해외	참고용
Celeb-DF	해외	실험 완료
K-FACE	국내	AI-Hub 승인 완료 (v3 예정)
딥페이크 변조 영상	국내	별도 딥페이크 판별 실험 전용

실험은 목적에 따라 서로 다른 데이터셋을 사용했다. 동일인 검증 baseline 실험(v1)은 정식으로 이용이 승인된 Celeb-DF의 실제 인물 영상으로 수행했고, 딥페이크 조작 기법 자체를 다루는 후속 연구는 FaceForensics++를 참고한다. 국내 데이터셋 중 가장 핵심적인 것은 한국인 얼굴 이미지로 구성된 K-FACE로, AI-Hub를 통한 이용 신청이 최근 승인되어 향후 파인튜닝 실험(v3)에 사용할 예정이다. 이 외에 AI-Hub의 딥페이크 변조 영상 데이터셋은 실제·합성 영상이 혼합된 자료로, 동일인 검증이 아닌 별도의 딥페이크 판별 실험에 한정해 참고한다.


3.2 얼굴가드 탐지 파이프라인



[그림] 얼굴가드 탐지 파이프라인


얼굴가드의 탐지 과정은 세 단계로 이루어진다. 먼저 사용자가 등록한 얼굴 사진에서 SCRFD 또는 RetinaFace 계열의 검출기로 얼굴 영역을 찾아내고 다섯 개의 특징점을 기준으로 정렬한 뒤, ArcFace 모델로 512 차원의 임베딩 벡터를 생성한다. 이 임베딩은 원본 이미지를 서버로 전송하지 않고 기기 내부에만 저장되어 사용자의 얼굴 정보를 보호한다. 이어서 등록된 얼굴을 기준으로 Google Cloud Vision의 Web Detection API를 호출해 공개 웹에 게시된 유사 이미지를 역이미지 검색으로 수집한다. 얼굴 임베딩 모델 자체는 어떤 이미지를 검사할지 스스로 판단할 수 없으므로, 이 단계에서 API가 탐지 범위를 사용자가 인지하지 못하는 공개 웹 전체로 넓히는 역할을 한다. 마지막으로 수집된 각 후보 이미지도 동일한 ArcFace 임베딩을 적용해 등록된 얼굴과의 코사인 유사도를 계산하고, 유사도 85% 이상은 즉각경보, 60~84%는 확인요청, 60% 미만은 로그기록으로 알림을 자동화한다.

3.3 ArcFace 이론적 배경




[그림] ArcFace 개념도 (출처: Deng et al., CVPR 2019 확장판, arXiv:1801.07698, Fig.1)

얼굴 임베딩 단계에서 사용하는 ArcFace는 임베딩 벡터를 초구 위에 정규화한 뒤 정답 클래스와의 각도에 가산적 각 마진을 부여해 학습하는 손실 함수다. 위 그림에서 보듯 기존 Triplet·Tuplet 손실이 미니배치 내 표본 간 지역적 비교에 그치는 것과 달리, ArcFace는 표본을 하나의 양성 중심(positive center)에는 가깝게, 나머지 모든 타인의 중심으로부터는 멀어지도록 학습하는 전역적 비교 방식을 취한다. 얼굴가드에서는 사용자가 등록한 얼굴이 이 양성 중심에 해당하고, 공개 웹에서 발견되는 무관한 타인들이 음성 중심에 해당한다.



[그림] ArcFace 학습 파이프라인

이 손실 함수의 학습 과정을 수식 단위로 보면, 정규화된 임베딩과 클래스별 중심 사이의 코사인 유사도를 행렬곱으로 구한 뒤, 각도로 변환해 정답 클래스에만 마진을 더하고, 다시 코사인으로 되돌려 스케일을 곱한 값을 softmax 와 교차 엔트로피로 학습한다. 딥소각이 사용하는 사전학습 buffalo_l 가중치는 바로 이 손실 함수로 대규모 얼굴 데이터셋에서 학습된 것이며, 앞서 소개한 K-FACE 로 진행할 버전 3의 파인튜닝 역시 이 손실 구조를 그대로 승계해 한국인 얼굴 데이터로 추가 학습하는 방식이 된다.



[그림] ArcFace 임베딩의 생성적 특성 (출처: Deng et al., Fig.8)

ArcFace 임베딩은 판별뿐 아니라 생성에도 활용될 수 있다. 사전학습된 ArcFace 모델의 그라디언트와 배치 정규화(BN) 층에 저장된 평균·분산 통계만으로 무작위 잡음을 특정 인물과 유사한 얼굴 이미지로 점진적으로 복원할 수 있다는 것이다. 얼굴가드는 이 생성 기능을 직접 사용하지 않지만, 이는 얼굴 임베딩 자체가 재구성 가능한 정보를 담고 있어 완전히 익명적이지는 않을 수 있음을 시사한다. 이러한 이유로 딥소각은 등록 임베딩을 서버로 전송하지 않고 기기 내부에만 보관하는 설계를 유지하며, 향후 서버측 처리가 필요해질 경우 암호화나 재구성 방지 기법을 함께 검토할 계획이다.


3.4 단계별 기술 검증과 한계 보완

얼굴가드는 ① 주어진 후보 얼굴 판별(v1) → ② 공개 웹 후보 발견·대조(v2) → ③ 한국인 실사용 환경 보정(v3) 순으로 탐지 범위를 확장하였다. 각 단계는 앞 단계에서 확인된 한계를 다음 기술로 보완하는 구조이며, v1·v2는 실측 완료, v3는 실행 계획 단계이다.

[v1 | 동일한 판별 기준선 확보]

v1의 검증 질문은 후보 이미지가 주어졌을 때 동일한 판별이 가능한가였다. 사전학습된 InsightFace의


buffalo_l(ArcFace) 가중치로 Celeb-DF-v2 의 Celeb-real 영상 590 개를 실험하고, 프레임 수(1·5·10)와 등록 영상 수(1·3·5)를 교차해 5 개 seed 로 반복 측정하였다. 등록 영상 3 개·영상당 5 프레임에서 평균 ROC-AUC 1.000, EER 0.000, TAR 1.000 을 기록했으나, FAR 0.00138 이 목표치 0.001 을 초과해 임계값을 운영값으로 채택하지 않았다. 또한 촬영조건이 균일한 데이터의 일반화 한계와 ArcFace 가 비교 후보를 직접 찾지 못하는 한계를 확인해 v2 에서 공개 웹 후보 수집 기능을 결합하였다.



[그림] Celeb-DF-v2 baseline 검증 결과

[v2 | 공개 웹 후보 탐지로 범위 확장]

v2 의 검증 질문은 사용자가 모르는 공개 웹 후보까지 수집·대조할 수 있는가였다. Cloud Vision API 가 공개 웹 후보를 수집하고 ArcFace 가 동일인 가능성을 대조하는 구조를 검증하였다. 표준 테스트 이미지에서 후보 20 건이 반환됐고, 현재 앱의 pHash 비교에서는 모두 100%의 이미지 유사도를 기록하였다. 동일 후보를 ArcFace 로 재측정한 결과 평균 코사인 유사도 0.981 을 기록했으며, 20 건 모두 임시 기준값 0.6 을 상회하였다.



[그림] Cloud Vision API 후보 20 건의 ArcFace 코사인 유사도 실측 결과(평균 0.981)

반면 팀원 김경민의 사진에서는 무관한 SNS 프로필 1 건이 유사도 0.62 로 포함돼 오탐으로 분류하였다.

이를 통해 v1의 주어진 후보 판별에서 v2의 공개 웹 후보 발견·대조로 탐지 범위가 확장됐지만, 실제 적용 전 다양한 동일·비동일 인물 검증셋을 활용한 임계값 조정이 필요함을 확인하였다. 현재 앱에는 pHash가 임시 적용돼 있으며, 다음 단계에서 ArcFace를 앱 파이프라인에 직접 연동한다. 상용화 전에는 InsightFace 라이선스를 검토해 상업적 이용이 가능한 가중치로 전환할 계획이다.

[v3 | 한국인 실사용 환경 보정]

v3의 검증 질문은 한국인 얼굴과 모바일 촬영환경에서도 오탐을 통제할 수 있는가이다. K-FACE 이용 승인을 완료했으며, 등록 이미지 3장·5장과 임베딩 상단 계층·backbone 전체 재학습 방식을 비교할 계획이다. 각도·조명·화질·압축 조건을 반영한 고정 검증셋에서 ROC-AUC·FAR·FRR과 임계값별 오탐 변화를 측정한다. 파인튜닝은 v1·v2가 사전 목표에 미달하고 그 원인이 얼굴 검출·정렬 실패만으로 설명되지 않을 때 진행하며, 검증 전 수치는 제시하지 않는다.

단계	방법	핵심 결과	상태
v1	ArcFace 얼굴 판별(Celeb-DF)	판별 기준선 확보 / FAR 목표 미달·후보 수집 한계	완료
v2	공개 웹 후보 수집·ArcFace 재측정	후보 20건·평균 0.981 / 오탐 1건 → 탐지 범위 확장	검증
v3	K-FACE 실환경 보정	한국인·모바일 환경 오탐·임계값 검증 계획	예정

4. 기대효과 및 활용방안

예방·탐지·대응 기능의 효과 검증 및 사업화 가능성 확인

4.1 설문·조사 기반 수요 검증


가장 필요한 기능 (복수응답, n=45)



[그림] 답소각 수요조사 결과(Google Forms, 2026.8.7., n=45)

학교 제공 시 이용 의향

77.8% 긍정 응답




10명 중 약 8명 | 35/45명 (4점, 5점 체크)

- 검증 과제: 개인정보 유출 우려 75.6%, NPS 0 점 → 원본 미저장·기기 내 처리 및 실제 MVP 재검증

4.2 시장 규모 및 수익모델

산출 기준: 교육부·한국교육개발원 2025년 교육기본통계와 기관당 연간 라이선스 2,400만 원을 적용한 공급가 기준 추정

확보 전략: 12~16 주 실증을 거쳐 연간계약으로 전환, 1 년 차 1 개교에서 3 년 차 누적 3~5 개교로 확대



12~16 주 실증 1,500 만 원 → 연간 라이선스 2,400 만 원 → 포함 한도 초과 시 API 사용량 추가 과금

4.3 단계별 확장 및 한계

단계	인정하는 한계	해결·검증 방향
해커톤 MVP	딥백신의 100% 합성 차단 불가, 비공개 채널 자동 탐색	공개 웹 탐지·사용자 제보·증거자료 생성의 E2E 가능성 우선 검증
3~6 개월	이미지 변형에 따른 성능 저하, 오탐·개인정보·반복사용 미검증	한국인 얼굴 임계값 보정, 보안검토, 대학 1 개교 실증을 통한 MAU·NPS·API 원가 측정
1~3 년	미참여 플랫폼과 암호화 채널의 재유포 차단 제한	기기 내 해시·C2PA·플랫폼 협력 및 Safe Upload API 기반 확장

- 한계 해결 이후 목표

게시 전 보호 → 공개 노출 조기탐지 → 증거·신고 준비 → 기관 연계 → 플랫폼 재업로드 방지로 이어지는 전주기 디지털 안전 인프라 구축

4.4 보안성 대응 방향

- **개인정보 보호:** 얼굴 원본은 기기 내 암호화 보관, 서버에는 최소한의 해시·사건정보만 전송. 사용자 동의 없는 외부 검색·기관 전달 금지 및 즉시 삭제 기능 제공

- **오류·복구 대응:** AI 판별 결과를 자동 신고하지 않고 사용자 확인 후 진행. API 장애 시 재시도·대체 처리, 처리이력 기록, 암호화 백업과 데이터 복구·롤백 체계 마련

5. 추진 일정

검증지표와 산출물을 연결한 단계별 실행계획

5.1 개발 일정 | 해커톤 본선 심사 일정에 따른 단계별 추진 계획

	1-2주 기반 구축		3-4주 핵심 검증		5-6주 통합·시연	
	1주	2주	3주	4주	5주	6주
지표·개인정보 설계						
데이터 전처리·Baseline						
딥백신·얼굴가드 구현						
정확도·강건성 검증						
앱·증거·신고 연동						
보안점검·시연 완성						

1~2 주 | 평가지표·개인정보 흐름·인물 분리 테스트셋 확정 및 ArcFace-EfficientNet Baseline 구축

3~4 주 | 딥백신·얼굴가드 연동, 각도·화질·압축 조건별 정확도·강건성 비교 및 임계값 조정

5~6 주 | React Native-FastAPI·증거·신고서 통합, 보안점검·3 개 사용자 시나리오·10 분 시연 3 회 완성

5.2 팀 역할

- 김경민: AI·얼굴가드·딥백신 개발 / 데이터·API·모델 성능 및 원가 검증

- 김다애: 서버·증거·신고 기능 개발 / 보안·기관 연계 및 기술사업화

- 최현준: 앱·사용자 흐름 개발 / 설문·시장·BM 및 발표 전략 수립